Упражнения: Използване на външна библиотека Tesseract

Ще направим малък примерен проект за разпознаване на текст от изображение чрез **Tesseract.**

Задача 1. Инсталиране на Tessearct чрез NuGet

Сега трябва да инсталираме **Tesseract** библиотеката чрез NuGet. За целта:

- Натиснете Ctrl + Q, за да използвате Quick Launch
- Въведете nuget
- Изберете Tools -> Library Package Manager -> Manage NuGet Packages for Solution...

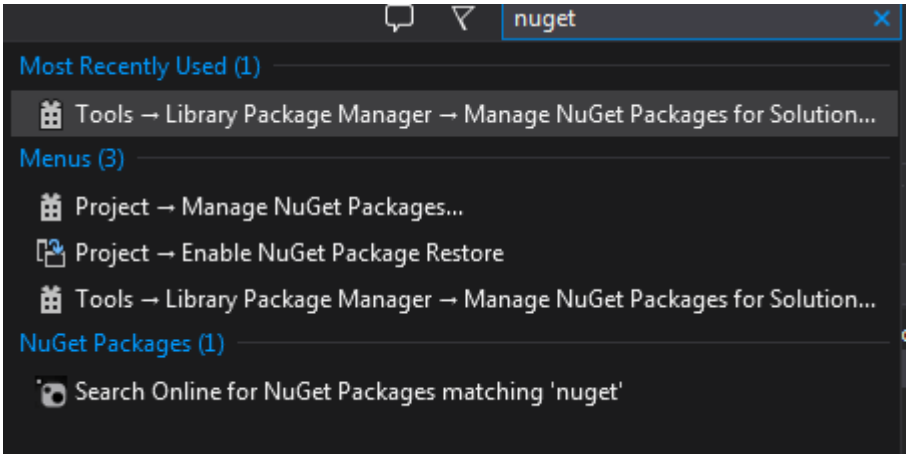

- Намерете Tesseract и инсталирайте.

Задача 2. Добавяне на файлове за разпознаване

Tessearct е библиотека за разпознаване на текст от изображение - Optical Character Recognition (OCR). Няма да навлизаме в техническите детайли на това как работи тази технология, а ще се концентрираме върху използването на библиотеката за тази нейна цел. За да разпознава успешно отделни знаци, **Tessearct** се нуждае от модел с данни. Ще използваме готов набор от данни. Файловете на модела трябва да бъдат поставени там където се създава .exe файла на приложението. В случая файла се намира в bin/debug папката на проекта. Там трябва да поставите и папката **tessdata**, която е предоставена като допълнителен ресурс.

Документът е разработен за нуждите на Национална програма "Обучение за ИТ умения и кариера" на Министерството на образованието и науката (МОН) и се разпространява под свободен лиценз CC-BY-NC-SA (Creative Commons Attribution-Non-Commercial-Share-Alike 4.0 International).

Задача 3. Добавяне на изображение за разпознаване

Файлът с изображението **test.png** трябва се намира в **bin/debug** папка **tessdata** на проекта.

Silicon Valley Bank collapses after failing to raise capital

Silicon Valley Bank collapsed Friday morning after a stunning 48 hours in which a bank run and a capital crisis led to the second-largest failure of a financial institution in US history.

California regulators closed down the tech lender and put it under the control of the US Federal Deposit Insurance Corporation. The FDIC is acting as a receiver, which typically means it will liquidate the bank's assets to pay back its customers, including depositors and creditors.

An SVB Financial Group chart displayed on the floor of the New York Stock Exchange in New York, US, on Friday, March 10, 2023. SVB Financial Group shares extended their plunge before being halted in premarket trading for pending news as prominent venture capitalists recommended companies withdraw their money from the lender, sparking further worries over its financial health and liquidity in the wider banking sector.

Silicon Valley Bank collapse has echoes of 2008. Here's why things are different this time
The FDIC, an independent government agency that insures bank deposits and oversees financial institutions, said all insured depositors will have full access to their insured deposits by no later than Monday morning.
It said it would pay uninsured depositors an "advance dividend within the next week."

The bank, previously owned by SVB Financial Group, didn't respond to CNN's request for comment.

Задача 4. Прочитане на текста от изображението

Програмният код, с който можем да извършим прочитане е изненадващо прост. Трябва да си създадем един низ, в който да запишем пълния път към файла и името му. След това създаваме обект от клас **TesseractEngine**, указвайки езика, на който е текста, както и името на папката с данните.

След това създаваме обект за изображението, а накрая чрез метода **Process** получаваме и обект за страницата – този обект има метод **GetText()**, който съдържа нашия текст.

```
string fileName = AppContext.BaseDirectory + "tessdata\\test.png";
using (var engine = new TesseractEngine(@"tessdata", "eng"))
{
    using (var image = Pix.LoadFromFile(fileName))
    {
        using (var page = engine.Process(image))
        {
            string text = page.GetText();
            Console.WriteLine(text);
        }
    }
}
```

За файл използвайте изображението от задача 3.

Резултатът от изпълнението на програмата е доста добър, макар и с известни неточности:

Документът е разработен за нуждите на Национална програма "Обучение за ИТ умения и кариера" на Министерството на образованието и науката (МОН) и се разпространява под свободен лиценз CC-BY-NC-SA (Creative Commons Attribution-Non-Commercial-Share-Alike 4.0 International).

```
Microsoft Visual Studio Debu

Silicon Valley Bank collapsed Friday morning after a stunning 48 hours in which a bank run and
a capital crisis led to the second-largest failure of a financial institution in US history.

California regulators closed down the tech lender and put it under the control of the
US Federal Deposit Insurance Corporation. The FDIC is acting as a receiver,
which typically means it will liquidate the bank's assets to pay back its customers, including depositors and creditors.

An SVB Financial Group chart displayed on the floor of the New York Stock Exchange in

New York, US, on Friday, March 10, 2023. SVB Financial Group shares extended their plunge before
being halted in premarket trading for pending news as prominent venture capitalists recommended
companies withdraw their money from the lender, sparking further worries over its financial health
and liquidity in the wider banking sector.

Silicon Valley Bank collapse has echoes of 2008. Here's why things are different this time
The FDIC, an independent government agency that insures bank deposits and oversees
financial institutions, said all insured depositors will have full access to their insured
deposits by no later than Monday morning.

It said it would pay uninsured depositors an "advance dividend within the next week."

The bank, previously owned by SVB Financial Group, didn't respond to CNN's request for comment.
```

Ще се задоволим на този етап с този резултат, но ще добавим, че все пак той може да бъде подобрен по редица начини, например:

- Допълнителна обработка на изображението, чрез методи и класове от библиотеката на **Tesseract** или външен софтуер
- Допълнително или по-добро трениране на данните на модела на **Tesseract.**

Документът е разработен за нуждите на Национална програма "Обучение за ИТ умения и кариера" на Министерството на образованието и науката (МОН) и се разпространява под свободен лиценз CC-BY-NC-SA (Creative Commons Attribution-Non-Commercial-Share-Alike 4.0 International).